

Human-Computer Interaction (HCI)

Significato

HCI è una disciplina che si occupa della *progettazione, realizzazione e valutazione* di sistemi *interattivi* con *capacità computazionali* destinati all'uso umano; e dello studio dei principali *fenomeni che li circondano*.

I sistemi computazionali *reali* sono utilizzati da persone reali in attività reali (= *destinati all'uso umano*).

Essendo l'uomo un essere sociale, l'Interazione Uomo-Macchina è anche *Interazione Uomo-Uomo Mediata dalla Macchina*, perciò si parla di *IUUMM*.

HCI: Origini

La disciplina dell'HCI nasce negli anni *Ottanta*. Infatti, in quegli anni si ebbe la diffusione di massa dei personal computer (1981:IBM PC, 1984:Apple Macintosh) e si tenne la prima conferenza *ACM CHI* (1983), la più importante conferenza internazionale scientifica del settore.

Ha le sue origini nell'intersezione di due aree disciplinari differenti:

- *ergonomia o fattori umani*
- *informatica*

Interdisciplinarietà

Nell'interazione uomo-macchina si uniscono tre filoni scientifici:

- *scienza dei computer*:
 - paradigmi di interazione
 - modelli di dialogo
- *scienza della progettazione*:
 - interaction design
 - industrial design
 - ingegneria dei fattori umani
 - ergonomia
- *scienze dell'uomo*:
 - psicologia
 - scienze cognitive
 - psicologia sociale
 - linguistica
 - scienze della comunicazione

occorre capire come creare un sistema che crei una coppia con l'essere umano, il quale deve trovarlo naturale ed intuitivo

Ergonomia

Progettare per l'*interazione* è progettare per l'*utente* (che fa qualcosa, che lavora, che agisce, ...). Per questo, si parla di *ergonomia* (ovvero, *lo studio delle attività*) e di *ergonomia cognitiva*.

L'*ergonomia cognitiva* è lo studio dell'*interazione* tra l'*uomo* e gli *strumenti* per l'elaborazione di informazioni, studiando i *processi cognitivi* coinvolti (quali percezione, attenzione, memoria, pensiero, ma anche *linguaggio* ed *emozioni*) e suggerendo *soluzioni* per migliorare tali strumenti.

Progettazione e Utente

Progettare per l'interazione è progettare per l'utente (che fa qualcosa, che lavora, che agisce, ...).

Non è possibile definire con esattezza chi è l'*utente*, ma di certo l'utente *non* è il *progettista*. L'introspezione volta a definire le caratteristiche del sistema non funziona, poiché il progettista non è in grado di immaginarsi come sono fatti gli utenti in quanto conosce nel dettaglio il sistema.

E' difficile progettare affinché l'interazione sia buona per tre ragioni:

- *varietà dei sistemi interattivi*
- *varietà degli utenti*
- *varietà degli scopi e degli usi*

(nel corso, noi studieremo come progettare per varietà e saremo interessati a ciò che è fuori da un workflow)

HCI: Temi

- criteri, metodi e strumenti per la *progettazione dell'interazione* tra esseri umani e sistemi interattivi e per la *valutazione dell'usabilità* dei sistemi interattivi.
- progettazione di *nuove tecniche di interazione*.
- valutazione dell'*impatto* dell'automazione nei contesti umani. Si distinguono due tipi di impatto:
 - impatto diretto nel breve, sui singoli e nel qui e ora (usabilità)*
 - impatto indiretto nel medio-lungo, sulla collettività (conseguenze inattese)*
- la metodologia da adottare è quella di essere creativi e professionali e di andare a verificare dagli utenti reali se l'approccio ha portato ad un sistema di qualità.
- sistema socio-tecnico.

N.B: l'usabilità è un tipo di effetto/impatto sugli utenti (sui singoli utenti), non una caratteristica intrinseca di un sistema.

Ecco perché non è possibile valutare l'usabilità senza il coinvolgimento degli utenti (o meglio, un gruppo di utenti rappresentativi di tutti gli altri) e sarebbe meglio valutarla in un contesto quanto più simile ad una situazione reale.

Sistema Socio-Tecnico

Un sistema socio-tecnico è un insieme di elementi interrelati ed eventualmente mutuamente dipendenti che, agli occhi di un osservatore esterno, appaiono come un'entità unitaria ma collettiva, con caratteristiche e comportamento proprio, solitamente autonomo ed intenzionale (ovvero, volto ad un obiettivo).

Un sistema socio-tecnico è un sistema in cui la *componente umana (sociale)* e quella *tecnica (tecnologia)* sono inestricabilmente legate tra loro e la loro *interazione* porta a fenomeni *emergenti imprevedibili* (ovvero, dove il tutto è maggiore della somma delle parti poiché esse interagiscono).

Le proprietà (o comportamento) del sistema *non* sono *desumibili* da quelle delle sue *parti*, prese isolatamente, ma bensì emergono proprio in virtù delle *interazioni* tra quelle (analisi solo post-hoc) in un determinato *ambiente* (analisi locale).

Anche i sistemi informatici presentano caratteristiche che emergono solo quando degli esseri umani li utilizzano.

Si tratta di un concetto ad *invarianza di scala*, ovvero applicabile dal piccolo team di lavoro all'intera società umana.

Proprietà emergenti:

- *funzionali* - riguardano il funzionamento del sistema, una volta che tutte le sue parti, assemblate come devono, funzionano correttamente.
- *non funzionali* - riguardano quanto bene opera il sistema in un determinato ambiente/contesto (*reliability, security, performance, safety, usability, comfort*).

I requisiti è bene che siano formalizzati a seguito di sessioni di osservazioni molto approfondite.

I requisiti possono fare riferimento al software oppure possono fare riferimento all'hardware.

Sistema S-T: STS Thinking

STS thinking è un approccio che è consapevole che le due componenti si *integrano* bene (fit) e si *ottimizzano* solo congiuntamente, in configurazioni *subottime (joint optimization)*.

- focus anche su *job satisfaction, workers' needs and skill enhancement*

L'*introduzione/appropriazione/adozione* di una tecnologia in un *contesto reale (sociale)* è parte di un *processo di cambiamento* operante su più piani.

Sistema S-T: Componente Sociale e Componente Tecnica

Un *sistema socio-tecnico* prevede una *componente sociale* ed una *componente tecnica*.

Anche dove si ha la massima espressione sociale, vi è sempre una componente tecnica.

Anche dove si ha il massimo elemento tecnico, vi è sempre un elemento sociale.

- *persone* - ergonomia, dimensione sociale, conoscenza tacita, convenzioni, unwritten rules
- *tecniche/tecnologie* - procedure, protocolli, divisione del lavoro, written rules

Sistema S-T: Conseguenze Inattese

Un sistema socio-tecnico è un sistema complesso, in cui è impossibile prevedere ogni possibile evoluzione. Si introduce il concetto di *conseguenze inattese delle tecnologie*.

effetto Peltzman o effetto cobra: imporre l'obbligo del casco e separare strada e pista ciclabile portano, paradossalmente, ad un aumento degli incidenti.

Conseguenze Inattese - OverReliance

Una tipologia di conseguenza inattesa è l'*overreliance* (*sovra affidamento*): se un sistema è troppo affidabile, si corre il rischio che sia troppo buono con la conseguenza che gli utenti lo utilizzino eccessivamente o ne abusino. Si distingue in:

- *overdependence o automation bias* - dipendenza eccessiva, eccessiva fiducia nella risposta del supporto alle decisioni e quindi causa errori di omissione o di azione quando i sistemi sono imperfetti.
 - mancanza di autonomia
 - abuso, utilizzo oltre i bisogni effettivi
 - mancanza, dimenticanza o ignoranza di un piano alternativo
- *overconfidence o automation-related complacency* - fiducia eccessiva, la fiducia che il sistema computazionale funzionerà sempre per come è stato progettato e quindi fa abbassare l'attenzione quando lo si utilizza.
 - pensare che non andrà mai giù
 - pensare che non ne deriverà mai un danno
 - pensare che non potrà mai sbagliare

Ripasso - Concetti Base

Progettare sistemi usabili è progettare per l'uso, quindi per qualcosa che il progettista non controlla e che dipende dall'utente e da quello che egli fa.

Per progettare sistemi usabili non esistono metodologie, si deve:

1. imparare per (non) imitazione e dall'esperienza
2. essere creativi (ma non troppo)
3. valutare il proprio Sistema coinvolgendo utenti veri
4. essere progettisti responsabili

Essere progettisti responsabili significa sapere che il proprio Sistema sarà il componente di un Sistema socio-tecnico, che può stravolgere o comunque modificare (ad esempio, la pratica di persone che lavorano).

Aspettatevi che il vostro lavoro possa avere conseguenze inattese, e lavorate per minimizzare l'impatto.

Bassa Usabilità, Danni e Problemi

La *bassa usabilità* è associata a *danni* (economici o materiali) e *problemi* (che costano nella loro gestione o mitigazione).

Gli utenti *non capiscono* come svolgere i propri compiti con il sistema.

Il sistema presenta *un'eccessiva quantità* di *funzionalità* e opzioni (low use).

Gli utenti *non capiscono* cosa il sistema stia facendo (poca trasparenza).

Interazione con le tecnologie spesso fonte di *emozioni negative* (frustrazione, ansia, disorientamento, ira), che portano l'utente a compiere errori più o meno gravi.

Mito di Dedalo ed Icaro - esempio di uso improprio, ovvero oltre alla finalità d'uso dello strumento
Di chi è l'errore? Dei progettisti (Dedalo) o degli utenti (Icaro)? Dipende, dalla spiegazione, dai limiti dello strumento, dall'utilizzo da parte dell'utente,

Indizi Visibili - Affordances

Gli *oggetti ben progettati* sono facili da *interpretare* e *comprendere*: contengono *indizi visibili* (*affordances*) del loro funzionamento.

Gli oggetti progettati male possono essere *difficili e frustranti da usare*: non offrono indizi o ne danno di sbagliati, oppure sono stati progettati curando l'estetica più che la funzionalità.

caffettiera del masochista, difficile o scomoda da utilizzare
spremiagrumi dell'artista, non funzionale

Usabilità

Due esempi che *non utilizzano* le *affordances*, dimenticandosi dell'*usabilità*:

Norman doors - un sistema (una porta) progettato così male da non avere idea di come si debba utilizzare (se spingere, oppure se tirare).

La tendenza del progettista a concepire oggetti o sistemi che non invitano all'uso (e all'uso corretto) sulla base di elementi visuali o indicazioni chiare (*affordances*), affidandosi quindi solo alla memoria, all'esperienza o all'intuizione e incontrando spesso il disorientamento o fraintendimento dell'utente.

Floyd toilets - la tendenza del progettista a complicare affari semplici ed a pretendere che basti scrivere una procedura per renderla ovvia a qualunque utente.

E' importante, e banale, creare un design che suggerisce un uso proprio.

Tre Concetti Centrali

affordance

mapping

constraints

Sistemi e Interfacce d'Uso

sistema interattivo (ISO 9241)

Combinazione di componenti hardware e software che ricevono input da un utente umano, e gli forniscono un output allo scopo di supportare l'effettuazione di un compito.

interfaccia (ISO 9241)

l'insieme dei componenti di un sistema interattivo (software o hardware) che forniscono all'utente informazioni e comandi per permettergli di effettuare specifici compiti attraverso il sistema.

concetto ricorrente tra le definizioni: compito (in inglese, *task*), perciò è importante quello che l'utente deve fare.

(Nokia cercò di mappare i task: sull'asse x da *con altri* a *da soli* e sull'asse y da *orientato ai task* ad *orientato al pleasure*)

Errore Comune! Dalla prospettiva IUM non si tratta di progettare interfacce “belle” nei loro aspetti estetici (visual design), ma di progettare gli elementi che permettono e vincolano l'azione dell'utente sul - e mediata dal - il sistema computazionale.

Si tratta quindi di *progettare l'interazione* (UM e UUMM) e di *preoccuparsi della sua qualità* (anche gli elementi estetici hanno un impatto sulla soddisfazione), considerando le modalità di fruizione del valore, le modalità di raggiungimento degli obiettivi (ovvero, *i compiti delle persone*) e delle conseguenze dell'uso.

Vincolo o Constraint

Un vincolo può essere di due tipi:

- *passivo o strutturale*
 - es. concepisco un form con tre campi e non quattro, per vincolare l'inserimento
 - es. non prevedo un campo “note”
 - es. non prevedo un canale di ritorno (feedback) tra consumatore ed azienda
- *attivo o funzionale*
 - es. concepisco dei controlli per cui l'utente non può proseguire se non compila tutti i campi o non li compila correttamente (sulla base di espressioni regolari, come per l'indirizzo email o il codice fiscale)

Sono strumenti per garantire una *migliore qualità dei dati* ed una *standardizzazione delle pratiche* (procedure) ma *non* bisogna *esagerare*, altrimenti si verifica il fenomeno del *workaround*.

Non bisogna esagerare con i vincoli altrimenti l'utente sviluppa l'ingegno oppure il **workaround**

= trovare un modo per aggirare l'ostacolo messo dall'informatico.

= qualsiasi azione relativa all'esecuzione di un processo o di un compito che non è prevista o descritta da manuali di uso del sistema informatico e o nei manuali che descrivono tale processo o procedura e che può baypassare l'uso del sistema o piegarlo ai propri fini.

= “circumvention” = workthrough

Shop floor = piano dei macchinari; bisogna parlare con questo piano che sono dei key informant, ossia degli informatori chiave per lo sviluppo del lavoro.

Capire i workaround è un modo per capire come migliorare il sistema.

Affordance

= fruibilità, invitabilità, intuitività, permissibilità

= (def. di Eleanor Gibson) è una risorsa o un supporto che l'ambiente dà all'animale; quest'ultimo deve avere le capacità di percepirla e utilizzarla.

Non è una caratteristica intrinseca ma è un qualcosa che deve accoppiarsi alle capacità o al contesto di un animale/persona.

= (def. di Donald Norman) è una qualunque qualità o proprietà di un oggetto che definisce i suoi possibili usi o rende chiaro come può o dovrebbe essere usato.

= aiutano gli utenti a fare qualcosa

Norman (psicologo) ha preso questo concetto da Gibson che a sua volta l'ha preso dalla teoria di Gestalt, e ha reso questo concetto dipendente non solo dalle capacità fisiche ma anche dalla cognizione del soggetto.

Quindi generalmente ci sono diversi tipi di affordance:

- cognitiva: riguardano l'utente (pensare, ricordare, imparare..)
- fisica: aiutano gli utenti nelle loro azioni fisiche
- sensoriali: utilizzo dei 5 sensi
- funzionali: aiutano l'utente a fare il vero lavoro e concludere le cose, a usare il sistema a fare il lavoro

+ affordance emozionali e sociali

Cognitive affordance

È una design feature per aiutare l'utente a fare un'azione cognitiva.

Giocano un ruolo importante nel design interattivo perché danno consigli all'utente su come procedere; per es. Il messaggio di errore come feedback è un affordance cognitiva perché è scritta e per capirla bisogna saper leggere e quindi usare la cognizione.

Affordance sensoriale: quando in un messaggio di avviso devi scegliere sì o no e uno dei due tasti è colorato e quindi ti incita a fare quella scelta.

Physical affordance

Sono quelle che ti incitano ad un'azione fisica.

Scheumorfismo = quando si passa dal reale al digitale di un oggetto si cerca di mantenere l'estetica così da dare l'impressione di avere l'oggetto in sé reale (per es. agenda iPad che aveva l'effetto del foglio che si può sfogliare come agenda fisica)

= progettare oggetti che derivano da altri che trattengono degli elementi ornamentali dalle strutture originali per dare l'impressione di utilizzarli.

Mapping

Il mapping è una affordance analogica.

Mapping diretto: (naturale) utilizza la somiglianza (pulsante vicino all'oggetto controllato da esso)

= viene naturale immaginare la relazione esistente tra controllo ed effetto. Per esempio il puntatore a forma di mano con il dito alzato per dare l'idea che si debba cliccare.

Mapping arbitrario: (convenzionale) immaginata dal progettista, l'utente se ne appropria grazie agli errori e poi la tiene a memoria, non ci sono indicazioni

Non esiste il mapping senza l'affordance ma esiste un affordance senza mapping!!!!

In un'auto l'acceleratore è mapping convenzionale mentre il freno naturale, comunque in entrambi i casi l'affordance è "pestare".

Un affordance non suggerisce solo un'azione su di essa ma anche un effetto sul mondo, infatti il mapping che è una caratteristica del affordance che rende questa relazione più chiara.

I Dispositivi per l'Interazione

Vi sono molteplici canali di interazione con le macchine:

- *vista* - schermi video, stampanti, occhiali, caschi (output)
- *udito* - dispositivi sonori, sintesi vocale (output)
- *tatto* - guanto (output)
- *mani* - tastiera, mouse, touchpad, joystick, touch screen, tavoletta grafica, guanto, riconoscimento di gesti (input)
- *voce* - riconoscimento vocale (input)
- *sguardo* - eye tracking (input)
- *postura* - sensori, sensore di prossimità degli smartphone (input)

Conviene Essere Superficiali

Con una *buona* interfaccia l'utente può svolgere il suo compito *dimenticandosi* che sta usando un computer (*la teoria del flusso*).

Una *buona* interfaccia dà benefici in termini di *più alta produttività, più basso turnover, più alto morale dello staff, minore frustrazione, stress, insoddisfazione, più alta soddisfazione data dal lavoro, ...*, che si traducono in *più bassi costi operativi*.

Infine, con una *buona* interfaccia si *riducono gli errori*.

esempi

Implementare una soluzione che consente di risparmiare del denaro.

errori di giustapposizione - errori che risultano quando si seleziona una voce per sbaglio, poiché si trova vicino a quella corretta.

implementare soluzione che fa risparmiare del denaro.

Perché Sviluppare un'Interfaccia Adeguata

A causa della *multifunzionalità*, poiché prima eravamo vincolati alla forma degli artefatti che ergonomicamente ottimizzavano l'interazione con l'utente, mentre ora si ha un singolo dispositivo.

L'Evoluzione della Tecnologia, la Complessità

> *nuovi bisogni, progettazione, nuovi servizi o prodotti (che portano a nuovi bisogni)*

Assistiamo ad un fenomeno noto come *accelerazione della complessità*, ovvero aumenta il ritmo con cui le nuove versioni sostituiscono le precedenti (prima: 5 anni, ora: 1 anno).

Si distinguono tre tipologie di complessità:

- *complessità funzionale* - numero di funzioni di un prodotto o servizio
- *complessità strutturale* - numero di componenti di un prodotto o servizio
- *complessità d'uso* - difficoltà di utilizzo di un prodotto o servizio

es. gesso/coltello, bassa complessità funzionale e bassa complessità strutturale

es. smartphone, alta complessità funzionale ed alta complessità strutturale

es. aereo/orologio, bassa complessità funzionale ed alta complessità strutturale

es. coltellino svizzero, alta complessità funzionale e bassa complessità strutturale

es. pattada, bassa complessità funzionale e alta complessità d'uso

es. orologio, bassa complessità funzionale e bassa complessità d'uso
es. smartphone, alta complessità funzionale e bassa complessità d'uso
es. coltellino svizzero, alta complessità funzionale e alta complessità d'uso

E' necessario semplificare l'uso a causa della pervasività della tecnologia nel mondo di oggi e della necessità di rendere la tecnologia accessibile a tutti, altrimenti chi non la sa o non la può usare viene tagliato fuori).

E' utile immaginare le *tipologie di complessità in uno spazio tridimensionale*, poiché esse sono tra loro legate. Si vuole muovere il *punto* in una *posizione vantaggiosa*.

L'*interfaccia* è un *filtro semplificatore*, che *abbassa la complessità d'uso* (asse verticale) senza cambiare la *posizione* del *punto* relativa alla *complessità funzionale* ed alla *complessità strutturale*.

La tentazione è quella di fare *show off*, ovvero vantarsi della complessità e della sofisticatezza della propria creazione. Bisogna pensare alla complessità d'uso come un problema e progettare l'interfaccia come un canale per comunicare con l'utente e semplificarli la vita.

Recap

1. *concetti fondamentali*: vincolo (o constraint), mapping, affordance e workaround.
2. non esiste una metodologia per progettare una buona interazione, se non: osservare, immaginare, prototipare, valutare con gli utenti.
3. evitare errori attraverso l'osservazione (*toilette di Floyd e porte di Normann*).
4. chiedersi se si complicherà la vita all'utente.

Modulo 2 - Valutazione dell'Usabilità

Valutazione dell'Usabilità:

- *confronto trasversale* - si confrontano due sistemi
- *confronto longitudinale* - si confrontano due versioni di un sistema

Valutazione Qualitativa

Si coinvolgono degli utenti (esperti del *task*) e/o esperti di usabilità per valutare sistemi interattivi, a qualunque livello di prototipazione, alla luce di principi di buona progettazione.

Il fine della valutazione qualitativa non è una misura (non quantità, ma qualità), ma si vogliono definire i possibili problemi di usabilità che un sistema può presentare se usato veramente.

Si dice qualitativa poiché si raccoglie l'opinione (interpretazione) di un esperto che non viene trattata in maniera quantitativa.

Ad ogni modo, non significa procedere in maniera vaga, ma si procede secondo un metodo, ovvero sistematicamente, e si riportano i risultati in maniera strutturata e completa.

Nella valutazione qualitativa, la prioritizzazione, ovvero assegnare priorità alle problematiche e risolvere prima quelle più rilevanti, è fondamentale.

Il risultato è un elenco di problemi di usabilità, associati ad una o più euristiche, pesati per gravità e collegati al principio di buona progettazione che il problema viola.

Indicazioni per il Design dell'Interfaccia Utente

(prescrittività ascisse, generalità ordinate)

- *principi* (bassa prescrittività, alta generalità) - indicazioni generali per la progettazione di interfacce utente usabili, basate su evidenza scientifica o sul generale consenso, derivano dalla conoscenza degli aspetti psicologici e sociali e sono indipendenti dalla tecnologia, sono espressi spesso in forma molto generale.
- *linee guida e design patterns* (bassa prescrittività, bassa generalità) - il concetto nasce in architettura, sono buone pratiche per facilitare l'adozione di un linguaggio comune e la diffusione di standard *de facto* e per suggerire soluzioni evitando di dover reinventare la ruota.
- *regole di progetto* (alta prescrittività, bassa generalità)
- *standard* (alta prescrittività, alta generalità) - spesso nascono come standard *de facto*, ovvero design pattern adottati dalla maggior parte degli utenti o dei fornitori, per poi diventare standard *de iure*, ovvero stabiliti ed armonizzati in legge.

Le *linee guida* ed i *design pattern* si applicano.
I *principi* della buona progettazione di sistemi usabili si seguono.

Tra gli standard, ISO 9241 (Ergonomics of Human System Interaction) è composto da diverse serie (ciascuna delle quali composta di diversi documenti), in diverso stadio di evoluzione (attualmente, una ventina di documenti).

Principi Euristici - Euristiche

Si considerano *principi* e non *linee guida* o *design patterns* perché si vuole valutare l'usabilità senza creare vincoli eccessivi su *originalità* ed *innovatività*.

I principi sono detti *principi euristici* o semplicemente *euristiche*.

Una *euristica* è un insieme di *concetti*, *riferimenti* e, soprattutto, *strategie*, adatte a risolvere un problema (nel nostro caso, la progettazione di sistemi interattivi usabili, senza considerare troppe informazioni).

La valutazione euristica è quindi la valutazione di usabilità svolta alla luce di un insieme di euristiche (note e ben definite) per identificare soluzioni di design che o si conformano o violano una o più euristiche di tale insieme.

Indicazioni per il Design: Autorevolezza

Vi sono diversi livelli di *autorevolezza* (o *forza dell'evidenza*): *affermazioni/evidenze di livello*

- *A* - completamente supportate da risultati di ricerca e dati empirici
- *B* - basate su pratica generalmente accettata (in maniera documentata)
- *C* - non ben documentate, ma supportate dall'opinione di professionisti esperti
- *D* - opinione individuale (del progettista)

Negli standard, sono solitamente recepite solo indicazioni di livello *A* e *B*.

I *principi di Nielsen* sono di livello *B* e *C*, alcune soluzioni specifiche ispirate a quei principi sono anche di livello *A*.

Una soluzione efficace ed originale, per definizione, non ha autorevolezza.

Euristiche Più Frequentemente Utilizzate nella Valutazione Qualitativa dell'Usabilità

(quale scegliere è questione di preferenze e finalità, ed ogni settore possiede le proprie euristiche; per il progetto, è meglio affidarsi a quelle di Nielsen)

Interaction Design Checklist

Prevede *capitoli*, ciascuno dei quali possiede delle euristiche:

- *Affordance*
 - i controlli vengono mappati ai risultati in maniera logica e semplice
 - vi è una chiara metafora tra controllo e mondo reale
 - la funzione del controllo è facilmente determinata a colpo d'occhio
 - le icone simboliche devono essere chiare per i nuovi utenti
- *Feedback*
 - tutti gli stati degli elementi sono illustrati in maniera chiara ed efficace
 - lo stato corrente del sistema deve essere facilmente compreso dall'utente
 - bisogna dare un feedback quando un task è completato
- *Simplicity*

- *Structure*
- *Consistency*
- *Tolerance*
- *Accessibility*

Si tratta di *principi vaghi*, poiché applicabili ad un *ampio spettro di applicazioni*, per ricordare di curare le *affordances* dell'interfaccia.

Standard ISO 9241-110

Sette principi del *dialogo uomo macchina*:

1. *Adeguatezza al Compito*
2. *Autodescrizione*
3. *Conformità alle Aspettative dell'Utente*
4. *Adeguatezza all'Apprendimento*
5. *Controllabilità*
6. *Tolleranza verso gli Errori*
7. *Adeguatezza alla Personalizzazione*

Principi Euristici di Jacob Nielsen

Sono *dieci* principi *basati* su un'analisi fattoriale di 249 problemi di usabilità, con cui si è derivato l'*insieme minimo* che *massimizza* la *potenza esplicativa*.

Vi è una *correlazione* tra *euristiche di Nielsen* e *principi del dialogo ISO 9241*.

principi euristici di Jacob Nielsen elaborati da Mussio

- *percezione*
 - far vedere lo stato del sistema (feedback)
 - adeguare il sistema al mondo reale (parlare il linguaggio utente)
 - controllo dell'utente e libertà (uscite indicate chiaramente)
- *cognizione*
 - assicurare consistenza (nell'applicazione, sistema, ambiente)
 - riconoscimento piuttosto che uso della memoria dell'utente
 - assicurare flessibilità ed efficienza d'uso (acceleratori/shortcut)
 - visualizzare tutte e sole le informazioni necessarie (estetica e design minimalista)
- *errori*
 - prevenire gli errori
 - permettere all'utente di correggere gli errori e non solo di rilevarli
 - help e documentazione

Valutazione Euristica - il Metodo

Si tratta di una *tecnica sistematica* di *ispezione predittiva*.

sistematica significa avere sotto mano la risorsa per capire quali sono i problemi dell'applicazione alla luce delle euristiche che l'applicazione viola.

vi possono essere differenti approcci, come prendere in considerazione un blocco di problemi (percezione, cognizione, documentazione, ...) ed esaminare l'intera applicazione in base ad esso, oppure esaminare l'applicazione nei suoi casi d'uso ed esaminare ciascuna problematica.

ispezionare significa usare direttamente l'applicazione.

predittivo significa trovare i problemi che probabilmente accadranno quando un utente non esperto userà l'applicazione.

Serve un gruppo di valutatori (*esperti di dominio, esperti di usabilità, entrambi*) che esamina il sistema ed identifica eventuali problemi di usabilità *rispetto ad un insieme prefissato di principi (euristiche, sette di ISO 9241 o dieci di Nielsen)*:

- *olistica* (non guidata, basata su una libera navigazione del sistema) o *task oriented* (uso dell'applicazione al fine di ottenere un determinato risultato)
- *con o senza osservatori*

Olistica o Task Oriented, Approccio Ibrido

Approccio ibrido, esplorare liberamente l'applicazione per 5 minuti e poi proporre un task tra i più importanti.

Osservatori e Valutatori

Dividendo la sessione in due parti, nella prima siamo noi ad usare liberamente il sistema senza osservatori (*valutazione euristica esperta*), nella seconda siamo noi gli osservatori mentre gli utenti scelti utilizzano il sistema (*valutazione euristica partecipata*).

Sono previsti $3 + 3 = 6$ *valutatori*. Sono sufficienti sei valutatori per trovare i *tre quarti* di tutti i problemi di usabilità, perciò non conviene coinvolgerne altri.

Per stimare il numero totale di problemi di usabilità di un sistema, si prende il numero di problemi trovati da una persona moltiplicato per il numero di problemi trovati da un'altra persona e diviso per il numero di problemi totali trovati da entrambi.

Il risultato è un elenco di problemi di usabilità, associati ad una o più euristiche, pesati per gravità.

Procedere nella seguente maniera:

1. scegliere un'applicazione.
2. concepire due o tre task.
*i task devono essere realistici (più o meno specifici) ed eseguibili
evitare suggerimenti e descrizioni dei singoli passi*
3. ciascun componente del gruppo esplora l'applicazione (valutazione esperta olistica) con uno dei form (disponibili su e-Learning, che ricordano i principi di Nielsen).
4. ciascun componente del gruppo, indipendentemente dagli altri, scrive un elenco di problemi, riconducendoli alla violazione di una o più euristiche.
5. presentare l'applicazione a tre utenti esperti e dare loro 3-4 minuti per esplorare l'applicazione (valutazione utente olistica). Dirgli che verrà registrato (apposito modulo da fare firmare, anche quello più snello) e di pensare ad alta voce mentre usa l'applicazione (think-aloud protocol analysis), esprimendo quello che gli piace e vuole fare e quello che non gli piace e non riesce a fare. Un componente del gruppo gli stia vicino senza prendere appunti, un altro prenda appunti, segnandosi tempi ed espressioni verbali particolari.
6. presentare uno dei task definiti al passo 2., meglio farlo con una presentazione o filmato che spieghi obiettivo e macro-passi.
per dire all'utente cosa fare: presentazione PowerPoint salvata come video e dedicare ad ogni slide un tempo pari a numero di parole / 200 (parole al minuto)

7. fare eseguire all'utente il task (non più di 3-4 minuti - valutazione utente task-based) e continuare con la protocol analysis. Se l'utente ha bisogno di aiuto, la persona vicina gli dia suggerimenti.
8. dalla sessione di uso di ciascun utente, estrarre collaborativamente un elenco di problemi di usabilità.
9. mettere insieme le liste di problemi individuati (6 in totale, 3 dei membri del gruppo e 3 degli utenti), decidendo cosa togliere e cosa lasciare, eventualmente cosa accorpare.
10. predisporre un questionario con il quale i membri del gruppo prioritizzano e con il quale fare prioritizzare a tutti (almeno ad uno) i problemi trovati.
11. associare ad ogni problema una o più euristiche violate (indirizzare le prime n)

Valutazione Euristica - Come Eseguire una Valutazione Euristica

1. ogni valutatore esamina il sistema da solo.
2. osservazioni raccolte scritte immediatamente o in fase di revisione delle sessioni di osservazione
3. fase di valutazione, tante schede quanti i valutatori.
4. i valutatori si incontrano in un debriefing meeting dopo la valutazione per..
5. ..redigere un rapporto unico con l'insieme *unione virtuosa* (decisioni prese all'unanimità) dei problemi. se anche solo un valutatore non condivide un problema, esso va lasciato nell'elenco con severità 0.
6. per ciascun problema codice univoco, breve descrizione, descrizione più lunga, euristiche violate, numero di valutatori che lo hanno identificato, due colonne per la prioritizzazione in una tabella.
7. l'elenco deve essere proposto ai valutatori per la valutazione della severità, assegnando un grado di severità da ogni problema:
 - 0 = non è un problema di usabilità
 - 1 = problema cosmetico accessorio, non necessario da risolvere
 - 2 = problema secondario, priorità bassa di risoluzione
 - 3 = problema rilevante, priorità alta di risoluzione
 - 4 = catastrofe di usabilità, risolverlo prima che il prodotto venga rilasciato
 per valutare la severità si considerano tre fattori:
 - frequenza* - comune o raro?
 - impatto del problema* - facile o difficile da superare?
 - persistenza* - one-time oppure l'utente può incontrarlo pur conoscendolo?

Matrice Problemi/Valutatori

Si tratta di una matrice avente come colonne i problemi di usabilità e come righe i valutatori. Quando un valutatore trova un problema di usabilità, si colora la casella corrispondente. E' importante ordinare i problemi di usabilità in una scala di difficoltà. Consente di capire quali sono i problemi più ricorrenti ed i valutatori abili a trovarli.

Walk-Up-And-Use System

Un *walk-up-and-use system* è un sistema così auto-esplicativo che un utente che lo utilizza per la prima volta oppure una singola volta può utilizzare il sistema efficacemente senza alcuna introduzione o formazione a priori.
es. ATMs, ticket machines, public information systems, museum displays,

Valutazione Euristica - Perché

Si tratta di una tecnica del più generale approccio detto *discount usability engineering*. Nielsen ha riscontrato un rapporto *benefit-cost* superiore a 1:50.

Tra i *vantaggi*: veloce ed i risultati sono già in forma interpretata.

Tra gli *svantaggi*: poco accurata (può non individuare dei problemi o produrre falsi positivi, ovvero problemi difficilmente riscontrabili) e non tiene conto degli utenti veri.

Valutazione Euristica - Risorse Necessarie

Richiede un sistema funzionante (oppure un prototipo o un mock-up), dei valutatori, un osservatore se si coinvolgono utenti esperti, una sessione di osservazione di 30-90 min. (per noi 5-15 min.), perciò ogni valutatore dovrebbe riesaminare l'interfaccia più volte.

Valutazione Euristica - Pianificazione

stima elapsed - tempo di calendario necessario per il completamento.

stima effort - tempo di lavoro effettivo necessario per il completamento.

Valutazione Euristica - Errori Frequenti

- aggregare i problemi non analizzandoli uno ad uno - *i problemi di usabilità vanno descritti uno ad uno*
- proporre soluzioni nella discussione di un problema - *la soluzione va proposta dopo la valutazione euristica (non richiesta)*
- considerare un solo principio alla volta ed indicare i problemi che violano tale principio - *si parte dai problemi e li si riconduce ad una o più euristiche (improbabile che un problema non possa essere ricondotto ad una euristica di Nielsen ma non impossibile, se un problema sembra riguardare più euristiche se ne indicano al massimo tre)*
- mischiare problemi e soluzioni - *l'output della valutazione è un elenco di problemi prioritizzati*

Prioritizzazione

Per ogni problema identificato dal gruppo, fare valutare indipendentemente la severità coinvolgendo una decina di *colleghi dell'azienda* ed una decina di potenziali utenti (*non colleghi dell'azienda*), ottenendo 20-30 *valutazioni ordinali di severità per ciascun problema*.

scala ordinale consente una valutazione più solida, robusta e attendibile di una valutazione basata sui voti

Il fine della prioritizzazione è *identificare i problemi più urgenti* da indirizzare con le *risorse a disposizione*.

- estrarre dal sistema di rilevazione (il questionario online) la tabella delle valutazioni (i problemi indicati sulle colonne, le valutazioni di severità sulle righe, una per singolo valutatore)
- per ciascuna riga considerare la classifica di severità adottando la *strategia di competizione standard* (aka 1224), costruendo una nuova tabella delle posizioni (a partire da quella delle valutazioni)

- per ogni riga applicare la strategia di competizione standard, detta, con una mnemotecnica, 1224, ovvero a pari merito la posizione è quella precedente e si salta quella successiva (ad esempio, 1134 sarebbe equivalente)
- il/i problema/i in testa sono quelli con il punteggio più alto

prob1	prob2	prob3		prob1	prob2	prob3
3	3	1	➔	1	1	3
4	5	3		2	1	3

- considerare *due fasce*: quella dei problemi a priorità alta considera le prime n posizioni, con n circa 20% del numero totale dei problemi t , e poi quella della restanti $t-n$ posizioni
 - solitamente, nella prima fascia le prime 3-5 posizioni, responsabili di circa l'80% di tutti i problemi (*Pareto*)
- contare, per ciascun problema, il numero di volte che esso è in prima fascia (p) e il numero di volte che è in seconda fascia (s)
 - per confrontare/verificare, script Python sulla pagina del corso
- assegnare il problema ad una fascia in base al confronto tra p ed s
 - se $p > s$, il problema è in prima fascia, altrimenti in seconda fascia
- eseguire un *test binomiale* per capire se la differenza tra p ed s è dovuta al caso, stabilendo tre fasce: in base al P value del test
 - > fascia alta con priorità significativa (se vuota, uno o due problemi, di solito i primi due, indicandoli con un asterisco annotato poiché nessun problema era da inserire nella fascia a priorità più alta, abbiamo deciso noi di inserire questi 2/3 e di inserirli nella fascia alta)
 - > fascia intermedia di non significatività
 - > fascia basse con priorità significativa
 - p value = o livello di significatività attuale/osservato, è la probabilità di osservare i dati osservati, o anche più estremi, alla luce di un'ipotesi
 - livello di confidenza = è il livello con cui è possibile concludere qualcosa dopo aver effettuato un'indagine statistica
- tutti i problemi nella fascia alta di priorità significativa dovranno essere risolti prioritariamente, e scegliere alcuni problemi dalla fascia di non significatività
- nella tabella dei problemi aggiungere due colonne: *fascia di priorità, media o mediana dell'indice di severità* (solo media se media=mediana, entrambe se media!=mediana)
 - *media aritmetica*, la più sensibile agli estremi
indicare anche la deviazione standard
 - *mediana*, il valore di mezzo dopo aver ordinato i valori
 - *moda*, il valore più frequente
 - per chiarezza, ordinare i problemi mettendo prima quelli che sono in prima fascia e risultati significativamente severi
 - riportare in una nota il numero di persone coinvolte

Fase di Rapporto

- *descrizione del design sperimentale*

cosa viene valutato, perché (dominio applicativo interessante/proficuo o passione), coinvolgendo quante persone, considerando quali task, aerogramma di profilazione, diagramma cartesiano delle expertise

- *elenco finale dei problemi prioritizzati*
tabella dei problemi, screenshot dei problemi più gravi (in aggiunta a descrizione testuale), matrice problemi/valutatori (ordinata) (formula x,y,z numero problemi valutatore1, valutatore2, totali giustificando x e y e commentando z), distribuzione problemi/euristiche
- *considerazioni finali*
legate al numero totale stimato di problemi, alla distribuzione dei problemi, alle citazioni notevoli dalle sessioni olistiche ed esperte

Le n schede di analisi da cui è stato redatto l'elenco finale come allegato/appendice.

Nella cartella di progetto mettere le registrazioni e i moduli consenso.

Euristica 1 - Fare Vedere lo Stato del Sistema

Il sistema deve informare continuamente l'utente di ciò che sta facendo e come sta interpretando gli input dell'utente.

L'utente deve poter capire l'effetto dell'azione passata sullo stato presente ed individuare le possibili nuove azioni.

Un *feedback* deve essere espresso in maniera concreta, non astratta o in termini generali. Fornire un *feedback* in caso di *malfunzionamento* e quando il sistema sta effettuando una *elaborazione*, soprattutto in caso di operazioni che richiedono una lunga elaborazione, o aspettando un *input*. Vi sono differenti *gradi di persistenza*:

se tempo di risposta < 0.1 sec. non serve un feedback

se tempo di risposta = 1/3 sec. mostrare che c'è attività in corso

se tempo di risposta > 3 sec. mostrare la progressione del lavoro

mostrare i cambiamenti. E' importante ciò che si comunica, ma senza comunicare troppe informazioni:

- *feedback peggiore* - si sta sovrascrivendo un file senza dire quale
- *feedback migliore* - si sta sovrascrivendo quale file con quale file e ulteriori dati

gradi di persistenza.

- *persistenza breve* - un *tooltip* che appare spostandosi su un pulsante
- *persistenza media* - rimane sullo schermo finché l'utente esplicitamente non lo riconosce
- *persistenza alta* - rimane una parte permanente dello schermo

Euristica 2 - Adeguare il Sistema al Mondo Reale (Parlare il Linguaggio dell'Utente)

Bisogna permettere all'*utente* di usare la sua *esperienza* nell'interagire con il sistema.

I *dialoghi*, se possibile, devono essere nella *lingua nativa* dell'utente, e le *icone* devono rispettare la *cultura (affordance percepita)*.

Per la *familiarità*, adottare le *notazioni* di utente e *convenzioni* sui nomi.

Per la *proiezione del mondo reale*, adottare *metafore familiari* (è necessario capire l'utente ed il contesto).

Per *parlare il linguaggio dell'utente* è necessario prima di tutto *capire chi è l'utente*.

- evitare di mischiare le lingue, ed utilizzarle adeguatamente
- accertarsi che le icone siano adatte al mercato di interesse

Euristica 3 - Controllo dell'Utente e Libertà

Gli *utenti* non si devono sentire *intrappolati* dal computer, ma devono sentirsi gli *attori* del dialogo che *controllano*.

Bisogna sempre offrire all'utente chiare *vie di uscita*, ovvero un modo per *uscire dalla situazione*, e *possibilità di undo*, ovvero un modo per *ripristinare lo stato precedente* (e così via all'indietro, senza limitazioni). *Vie di uscita* e *undo* permettono all'utente di *imparare esplorando* il sistema.

Bisogna permettere di *interrompere o cancellare operazioni* che *durano troppo*.

dare all'utente controllo e libertà.

undo. il numero di funzioni di *undo* possibili deve essere *pari a quello dei comandi presenti*. alcuni *comandi* sono molto *difficili da recuperare*.

redo. consente di *ripristinare l'azione annullata dall'ultimo comando di undo*.

flip undo. l'*ultimo undo* annulla l'effetto dell'*undo precedentemente effettuato*.

multiple step undo. eseguire *undo* un numero *indefinito* di volte, fino a quando il *sistema ha informazioni* disponibili riguardo le *precedenti operazioni*.

Euristica 4 - Assicurare Consistenza

Si tratta di uno dei *principi alla base dell'usabilità*.

E' importante la *somiglianza in situazioni simili o perseguendo scopi simili*. Se lo stesso comando o la stessa azione hanno sempre lo stesso effetto, l'utente acquista *confidenza* con il sistema ed è incoraggiato ad *esplorare*, altrimenti si potrebbe *disorientare* l'utente.

Generalizzabilità: supportare gli utenti ad estendere la loro esperienza da situazioni note a situazioni mai incontrate.

Si deve anche mantenere *consistenza nel layout dell'interfaccia*: presentare la stessa informazione sempre nella stessa locazione.

Nell'ambito del *gruppo di sviluppo* è importante *definire rigorosamente e rispettare convenzioni interne di rappresentazione*.

Le *barre*, o *toolbars*, sono i *luoghi del controllo* da parte dell'utente, dove avviene gran parte dell'*interazione attiva*.

Nella *valutazione olistica* prendersi del tempo per *osservare la pagina principale*, dove si trovano le barre, quali comandi offrono, se ci sono ridondanze o inconsistenze, e per *fare ipotesi* sul *funzionamento* del sistema (controllare *miss matches* tra quello che si capisce e quello che il sistema fa).

Evitare la *contrapposizione* tra *rosso* e *verde*, utilizzare il *rosso* per *catturare l'attenzione* e riportare *come prima da leggere* l'*opzione alternativa*.

In caso di dubbi sulla soluzione migliore, *impostare un test*.

L'*A/B testing* consiste nel mostrare una *stessa soluzione* ad uno *stesso gruppo* e un'*altra soluzione* ad un *altro gruppo* e confrontare precisi *parametri*. Chiedersi sempre *se la differenza è statisticamente significativa*:

- non è necessariamente vero che se non c'è significatività statistica non c'è significatività pratica
- viceversa, non necessariamente se c'è significatività statistica c'è anche significatività pratica, dipende dalle differenze in gioco

DOMANDA ESAME SCRITTO: Che cos'è l'*intervallo di confidenza*?

Un intervallo di confidenza è un intervallo, ovvero un insieme di valori compresi tra due estremi, all'interno del quale si è sufficientemente confidenti si trovi il vero valore che verrà assunto dalla popolazione di riferimento. In pratica, indica quanto è *incerta* la stima.

L'*ampiezza* degli intervalli di confidenza dipende dalla variabilità dei dati e dalla numerosità del campione.

Euristica 5 - Riconoscimento Piuttosto Che Ricordo

esempi

- *ricordo* - non richiedere all'utente dati che il sistema già conosce
- *ricordo* - ricordare all'utente il formato corretto per date, range, ...
(esistono vari formati per selezionare una data: libera, menù a tendina, calendario)

In generale, esplicitare il formato qualora si effettuino controllo di correttezza e consistenza.

- *riconoscimento* - anteprime (nel caso di immagini) e scritte autoesplicative

Euristica 6 - Assicurare Flessibilità ed Efficienza d'Uso

L'*utente esperto* deve poter *svolgere velocemente* le operazioni *più frequenti*. Gli *shortcut da tastiera* (o *scorciatoie* o *acceleratori*) ne sono un classico esempio.

Inoltre, in termini di *flessibilità*, il sistema deve permettere di fare *le stesse cose in maniere differenti*. Non si tratta di *inconsistenza*, ma di una *scelta* sulla *modalità di interazione* più congeniale all'utente.

esempi

- segnalibri
- breadcrumbs trail
- storia dell'interazione
- templates e macro

- type-ahead (ovvero, poter inserire il prossimo input prima che il computer sia pronto ad accettarlo)
- fornire valori di default

Euristica 7 - Visualizzare Tutte e Sole le Informazioni Necessarie

L'interfaccia deve essere *semplice (minimalist design, material design di Google)* e *gradevole (aesthetics matters)* e *rispecchiare* nella maniera più naturale possibile i *compiti dell'utente*.

Ogni *scritta* posta nell'*interfaccia* è una *tentazione alla lettura*. Presentare solo l'informazione:

- *che* l'utente vuole
- *quando* l'utente la vuole
- *come* l'utente la vuole
- *dove* l'utente la vuole
- *non* accompagnata da informazioni *non rilevanti* o *fuorvianti*
- *insieme* ad altre informazioni raggruppate per *contesto d'uso*

una credenza errata. "più opzioni sono offerte e più modi di fare le cose sono messe a disposizione, più utenti vengono soddisfatti", noto come *bells and whistles bias*.

Ogni volta che si *aggiunge* un'*opzione*, l'utente ha una cosa in più da *imparare* e da utilizzare, potenzialmente, in maniera *scorretta*.

Un'alternativa è utilizzare diversi *modi utente*.

più pulsanti possono avere funzioni diverse in base alla modalità utente corrente è possibile capire la modalità utente in cui ci si trova tramite l'aspetto del puntatore

Il fenomeno del *Low Use* riguarda il rapporto tra le *funzioni usate spesso o a volte* e le *funzioni che non sono note*, oppure *sono note ma usate praticamente mai*.

Uno *use index* si calcola nella seguente maniera: (*media pesata*)

$$UI = ((\text{numero di funzioni usate spesso} * 1) + (\text{numero di funzioni usate a volte} * 0.5) + (\text{numero di funzioni mai usate} * 0)) / (\text{numero di funzioni considerate})$$

I *low users* sono quelli con $UI \leq 0.5$.

Ragionare in termini di *low users* consente di capire *quanto potenziale* dell'*applicazione* gli utenti stanno sfruttando, in quanto si vuole che *aumenti*.

Identificare le funzionalità a maggiore uso consente di *prioritizzare* le attività di *manutenzione correttiva* (ovvero, *correzione di bug*) ed *evolutiva* (ovvero, *introduzione di miglioramenti*). L'idea è *puntare sulle funzionalità più usate*, lasciando indietro quelle meno utilizzate.

importanza della grafica, del layout e del colore (estetica).

- porre *prima* le informazioni che devono essere *lette prima*
- *oggetti lampeggianti* o *caratteri maiuscoli* da utilizzare *solo se necessario*, anche perché *rallentano del 10% la velocità di lettura*
- non utilizzare più di 5-7 colori, non utilizzare *colori brillanti* per lo sfondo
- assicurarsi che gli elementi dell'interfaccia si distinguano anche senza i colori

- non dedicare troppo spazio a titolo, nome del venditore, numero di versione ed informazioni simili

In generale, si considera una *velocità di lettura media* di 200-300 *pam* (*parole al minuto* o *wpm*) per la lettura generica (*reading*), ma la velocità dipende dal compito, dall'illuminazione, dal font utilizzato e dal livello di scolarità:

- *memorizzazione* $M = 100$
- *skimming* $M = 700$
- *out-loud* $M = 150-180$
- *silent reading* $M = 250-300$

Per calcolare la *persistenza di messaggi* di *alerta* o *help*, considerare 200 *pam*.

Euristica 8 - Prevenire gli Errori

Individuare le possibili *situazioni di errore* e cercare di *aiutare l'utente*.

Per *ridurre* gli errori si potrebbe creare *meccanismi di prevenzione*, prevedere *richieste di conferma* per le azioni, evitare *comandi troppo simili* con *significati diversi*, creare *meccanismi di comunicazione utente-progettista*.

tecniche di prevenzione degli errori.

- *diversificare le azioni dell'utente* - una tecnica per prevenire i lapsus ed evitare che l'utente esegua inavvertitamente un'azione al posto di un'altra. in caso di ridondanza, l'utente adotterà la soluzione a lui più congeniale.
- *amodalità* - nel *comportamento modale* il sistema si comporta diversamente (ovvero, agli stessi controlli sono associate funzionalità diverse) a seconda dello *stato* (o *modalità*) corrente.
- *funzioni vincolate* - progettare funzioni in modo da rendere impossibili le azioni non lecite nel contesto corrente.
- *avvertimenti* - si adotta l'approccio *note* (*tieni presente che*), *caution* (*è proprio questo ciò che vuoi?*), *stop* (*fermo*).
- *richieste di conferma* - chiedere sempre conferma prima di effettuare *azioni irreversibili* o *pericolose*.
- *default inoffensivi* - ovvero, che, anche se confermati dall'utente sovrappensiero, non causerebbero inconsistenze nella base di dati.
- *bypass sicuri*

Euristica 9 - Permettere all'Utente di Correggere gli Errori e Non Solo di Rilevarli

I *messaggi di errore* dovrebbero presentare un *linguaggio chiaro, gentile e senza codici* ed *indicazioni precise* su come risolvere il problema.

Il termine *recoverability* indica la capacità di raggiungere comunque il risultato voluto, dopo aver commesso l'errore.

Linea di principio da seguire: *azioni difficili da correggere dovrebbero essere difficili da fare*.

in caso di errore. Si distinguono *tre livelli*:

- *alert* - dire che qualcosa non va
- *identify* - dire cosa non va
- *direct* - dare indicazioni su quello che è opportuno fare

granularità dei messaggi di errore. Comunicare un messaggio di errore per volta oppure tutti i messaggi insieme. La soluzione migliore è fornire informazioni contestuali (ad esempio, in un form indicare l'errore per ogni campo dopo aver provato a convalidarlo)
Inoltre, non bisogna creare trappole, ovvero non dare sufficiente tempo all'utente per correggere l'errore.

indicazioni sui messaggi di errore.

1. *dire cosa è successo e perché*
si deve poter capire il problema leggendo il messaggio di errore.
2. *suggerire il prossimo step*
si deve dare sufficienti informazioni all'utente per guidarlo fuori dall'errore.
3. *trovare il giusto tono*
4. *non incolpare l'utente ed essere umile*
un tono neutro risulta quasi sempre adeguato
5. *leggibile dall'essere umano*
6. *evitare il testo in maiuscolo*

progettare per l'errore, in sintesi.

- *prevenzione*, comprendere le cause di errore e minimizzarle
- *facilitare la scoperta* degli errori, che comunque accadono, e facilitarne la *correzione*
- *undo*, rendere ogni azione reversibile e rendere difficili le azioni irreversibili
- *cambiare atteggiamento verso l'errore*, non giudicarlo giusto o sbagliato ma come un'approssimazione verso l'obiettivo

Euristica 10 - Fornire Aiuto e Documentazione

Siccome il *sistema perfetto*, così facile da usare che non ha bisogno di help e manuali, ancora *non esiste*, è sempre bene *prevedere help e manuali*.

Ma gli *utenti non leggono i manuali*, preferiscono *provare a usare* il sistema, senza aver letto alcuna spiegazione.

E' utile fornire *help in linea (tooltip)* con documentazione raggiungibile in maniera precisa, e *manuali* nel momento in cui l'utente vuole diventare *più esperto*. Sono risultati utili anche *video e tutorial*.

L'*help* deve essere *minimalista e concettuale*, anch'esso può presentare *problemi di usabilità*.

Sotto il punto di vista della *conformità* dell'*applicazione* rispetto ai *regolamenti*, le *aziende* sono tenute a *documentare* il *software* e a fornire agli utenti *aiuti*, online e offline, non necessariamente cartacei ma sono possibili soluzioni alternative (ad esempio, un fumetto per iniziare l'utente e poi approcci come tooltips).

Valutazione dell'Usabilità (Qualità)

Approccio Quantitativo - Statistica Inferenziale

Cos'è il Successo di un Sistema Interattivo?

- gli utenti scelgono il sistema
- gli utenti sono disposti a pagare il sistema
- la market share cresce a spese degli altri
- il fatturato cresce ed i ricavi crescono
- gli utenti ne parlano bene e lo consigliano ai conoscenti
- gli utenti considerano il sistema parte della loro vita

Caratteristiche di un Sistema di Successo

- *utile* - deve fare quello che viene richiesto
se ne occupa il *software engineering*
- *usabile* - deve consentire di fare quello che viene richiesto in modo naturale, senza aumentare i rischi di errore, ... (argomenti da qui fino alla fine del corso)
se ne occupa l'*interazione Uomo - Macchina* in fase di *pre-deployment*
- *usato* - deve rendere le persone desiderose di usarlo, quindi deve essere interessante, divertente, piacevole (*user experience, interaction design*)
se ne occupa *Data Analytics* e *interazione Uomo - Macchina* in fase di *post-deployment*

Usabilità

Il *grado* con cui un prodotto *può* essere usato da *determinati utenti* per raggiungere *determinati obiettivi* con *efficacia, efficienza e soddisfazione*, in un *determinato contesto d'uso* - Standard ISO 9241.

si utilizza il termine *può* poiché la definizione contiene un certo grado di *indeterminatezza* dipendendo dalle tre dimensioni: *contesto d'uso, obiettivi e utente*.

- *grado* - si possono definire metriche per misurare l'usabilità
 - mappatura da fenomeno a un valore
- *metrica* = metodo con il quale si ottiene il mapping . insieme
- *efficacia* - indica il grado di correttezza, accuratezza, completezza in cui l'utente raggiunge i suoi obiettivi
- *efficienza* - indica il rapporto tra le risorse usate utili per raggiungere il risultato e quelle effettivamente consumate (concetto di spreco)
effectiveness is doing the right things
efficiency is doing these things right
- *soddisfazione* - quanto è soddisfatto (contento) l'utente, perciò è legata al concetto di esperienza piacevole
- *contesto d'uso* - vi sono differenze tra contesto di primo utilizzo, in emergenza, in condizioni di distrazione o affaticamento. si parla di contesti d'uso comuni, normali, frequenti o previsti

L'*esperienza d'uso* è ciò che una persona *prova* quando *utilizza* un *prodotto, sistema o servizio*. Dunque, ha una *natura soggettiva*, poiché coinvolge le *emozioni*, e *dinamica*, dal momento che si *modifica nel tempo* al variare delle circostanze.

domanda scritto: *non* ha senso parlare di usabilità di un *sistema in sé*, bensì ha senso parlare di usabilità in un *determinato contesto d'uso*. Perciò, ha senso parlare di *potenziale usabilità*.

misura e misurazione.

La *misura* è il risultato della misurazione. Un'assegnazione empirica ed oggettiva, mappatura, di un valore (numerico o simbolico) ad un fenomeno, per caratterizzarne un attributo specifico. Quando l'attributo *non* è *fisico* si parla di *indicatore*.

La *metrica* comprende la misurazione quantitativa del grado di possesso di un attributo da parte di un sistema, e definisce anche procedure, modalità e regole di misurazione:

entità da misurare, unità di misura e procedura

Una *differenza praticamente significativa* è quella che fa differenza.

Una *differenza statisticamente significativa* significa *non dovuta al caso*.

E' possibile avere una *differenza statisticamente significativa* che *non è significativa ai fini pratici*.

estensioni dell'usabilità.

- *robustezza* - il sistema deve indurre un basso tasso di errore, facili da correggere e con basso impatto.
- *apprendibilità, learnability* - facilità nell'apprendere il comportamento del sistema. *per utenti novizi*.
- *ricordabilità, rememberability* - facile da ricordare, anche quando l'utente riutilizza il sistema dopo diverso tempo. *per utente occasionali*.

Talvolta conviene progettare *sistemi difficili da imparare*, che danno *soddisfazione* all'utente esperto, creando *fidelizzazione* e rendendo difficile il passaggio ad altri sistemi.

Altre volte conviene progettare sistemi che *piacciono fin dall'inizio*, pur essendo più facile passare ad altri, poiché *la prima impressione è ciò che conta*.

Ovviamente, un sistema con *entrambi i profili non esiste*, occorre trovare un *compromesso*.

Potrebbero essere necessari dei *trade-off* tra *robustezza* ed *efficienza*, da *risolvere* definendo *quali dimensioni di usabilità* sono più *importanti* per un determinato sistema.

Valutazione di Usabilità

Attività di raccolta dati sull'*usabilità* di un *sistema informatico interattivo* rispetto a uno specifico *gruppo di utenti*, nello svolgere una certa *attività*, in un certo *ambiente*, o in un certo *contesto di lavoro*.

- *nello svolgere una certa attività* - collegare la valutazione all'analisi

caratteristiche.

- *empirica* - che coinvolge un campione di utenti veri.
- *concreta* - eseguita su sistemi reali (ovvero, che *interagiscono*).
- *sistematica* - da eseguirsi applicando un metodo

categorie di valutazione. Sono sei le categorie di valutazione, *non disgiunte*:

- *formativa* - rivolta ad identificare problemi o opportunità di miglioramento, utile come strumento di miglioramento nel processo iterativo di sviluppo prototipale.
- *riassuntiva* - giudizio sul prodotto (dopo lo sviluppo), per avere una misura di usabilità in termini assoluti o comparativi.
- *assoluta*
- *comparativa*
- *qualitativa*
- *quantitativa*

perché la valutazione di usabilità.

La valutazione serve per (*capire il mondo reale*) *confrontare* progetti e sistemi e *verificare* la *conformità* agli *standard*.

Valutazione di Usabilità - Come?

Raccolta dei Dati

Si raccolgono *dati* (*numerici, ordinali o categorici*) da un campione di utenti del sistema:

- *variabile numerica* - variabile scalare
- *variabile ordinale* - insieme di numeri in cui vi sono definite relazioni d'ordine totali, ovvero senza uguaglianze
- *variabile categorica* (o *nominale*) - parole
- *scala a rapporti* - esiste un punto zero assoluto che indica l'assenza della quantità misurata, le differenze tra i valori ed i rapporti sono significative (es. Kelvin).
- *scala a intervalli* - le differenze tra i valori sono significative e uguali, ma non esiste un punto zero assoluto, lo zero non rappresenta l'assenza della quantità misurata (es. Celsius).

errori.

Calcolare la media di variabili ordinali, si può invece calcolare la *mediana*. In caso di variabili categoriche, calcolare la *moda*.

Calcolo delle Statistiche

Si calcolano poi le *statistiche*. Nel caso dei *numeri* (ad esempio, il tempo di esecuzione di un task) si possono applicare *T di Student* e *ANOVA*. Nel caso di *dati non numerici* (ad esempio, il numero di risposte di un certo tipo) si possono applicare *test binomiale*, *test del Chi Quadro*, *test di Mann-Whitney* e test di Kruskal-Wallis. Nel caso di valori come *sì* e *no* si possono applicare *test binomiale* e *test del Chi Quadro*.

Si possono calcolare diversi momenti:

- *di primo grado* - indicatore di tendenza centrale (ad esempio, la *media*)
- *di secondo grado* - (ad esempio, *deviazione standard*)
- *di terzo grado* - (ad esempio, *skewness*, ovvero la *simmetria* rispetto alla media)
- *di quarto grado* (ad esempio, *curtosi*, ovvero la forma di una distribuzione)

Non si conosce il *parametro di una popolazione*, ma solo la *statistica di un campione*. Non si può essere precisi (*errore standard*), ma si può stimare l'*intervallo che è ragionevole pensare contenga il parametro reale (intervallo di confidenza)*. L'intervallo di confidenza indica l'incertezza intrinseca nella stima del parametro. L'intervallo è *simmetrico rispetto alla media* calcolata.

cosa significa l'intervallo di confidenza.

Un intervallo di confidenza del 95% *non significa* che esiste una probabilità del 95% che il *parametro* della popolazione sia *compreso tra i due estremi* dell'intervallo.

In un *numero molto grande di campioni*, il 95% degli intervalli conterrebbe la media vera della popolazione.

che è come dire che l'intervallo di confidenza è la percentuale di intervallo di confidenza, creati a partire dalla popolazione, che si pensa contengano il vero valore (su 100, per un intervallo di confidenza al 95%, 05 di essi conterebbero il vero valore).

estremi dell'intervallo.

Per conoscere gli *estremi dell'intervallo*, chiamati *livelli fiduciali*, si prende la statistica e si somma e sottrae il *marginale di errore*:

$\text{<errore standard>} * t$

dove t è una costante che dipende da quanto si vuole essere certe che l'intervallo di confidenza contenga il vero parametro

il *marginale di errore* è due volte l'*errore standard*

(ad esempio, per un intervallo di confidenza del 95%, t vale 1.96)

(ad esempio, per un intervallo di confidenza del 99%, t vale 2.58)

errore standard - formule.

L'*errore standard per la media* è il rapporto:

$(\text{deviazione standard}) / (\text{sqrt}(\text{numero dei membri del campione}))$

L'*errore standard per le proporzioni* è:

$\text{sqrt}((p*(1-p)) / (\text{numero dei membri del campione}))$

dove $p*(1-p)$ è la *variabilità massima*

Più è alto il *livello di confidenza*, maggiore è l'*intervallo di confidenza*. Infatti, più si vuole essere certi che l'intervallo contenga il vero valore, più l'intervallo di confidenza deve essere ampio.

All'*aumentare della numerosità del campione*, *aumenta la precisione*, e *minore* è l'*errore standard*. Infatti, si riduce l'ampiezza dell'intervallo.

confrontare l'efficacia di due applicazioni tramite confronto di proporzioni.

Si opera un'*analisi intervallare*: inserire i dati (successi e fallimenti rispetto al numero totale di utilizzi) per ottenere una *proporzione*, considerare l'*intervallo di confidenza* e determinare

se si *sovrappongono*. In questo caso, l'efficacia della prima applicazione *non è significativamente diversa* dall'efficacia della seconda applicazione. L'*analisi intervallare* è utile poiché è *significativa*, ovvero fornisce una *differenza importante* quando è molto *probabile* che tale differenza ci sia davvero. Al contrario, il *test di ipotesi* potrebbe fornire dei falsi positivi.

Confronto

Approccio di Neyman

Si *confrontano* gli *intervalli di confidenza*. La *differenza statisticamente significativa* si trova confrontando gli *intervalli* che *non si sovrappongono* rispetto alle ordinate.

(l'intervallo di confidenza contiene il vero valore, spostandosi dalla media. se, ad esempio, lo zero non incluso indica che vi è differenza significativa, allora se non è compreso nell'intervallo di confidenza c'è differenza significativa).

Approccio di Fisher

Si formulano *test di ipotesi* e si verificano con essi le *ipotesi nulle* H_0 . L'*ipotesi nulla* è assunta come *vera* e prevede che non ci siano differenze tra:

- i sistemi s_1 e s_2 , per la stessa caratteristica
- per il sistema s tra la versione a tempo t_0 e quella a tempo t_1
- tra strati, o *gruppi*, di *utenti*

L'*ipotesi nulla* sarà sempre:

H_0 : *non ci sono differenze statisticamente significative tra A e B*

(H_1 : *ci sono differenze statisticamente significative tra A e B*)

Quindi, si *assume* che *A non sia meglio di B* per *qualsunque cosa* si voglia analizzare in termini di *usabilità*, e si *raccolgono dati campionari* per *rigettare* l'*ipotesi nulla*.

Il Rituale Nullo

Si tratta di una procedura *statistica inferenziale* sintesi dell'approccio di Fisher e di Neyman-Pearson:

- si sceglie il test giusto per l'*ipotesi* ed il tipo di dato che si raccoglie
 - si esegue il test e si calcola il corrispondere *livello di significatività osservato* dei dati, anche detto *p-value*
 - si riportano i risultati in uno stile chiaro e *confrontabile*, ad esempio *standard APA*
1. definire l'*ipotesi* di ricerca dello studio
 2. operationalizzare l'*ipotesi* ed impostare le variabili oggetto di studio
 3. stabilire le *ipotesi nulle* e le conseguenti alternative
 4. impostare il livello di confidenza e, conseguentemente, il livello di significatività solitamente, al 5% o 1%
alpha è la probabilità associata al rischio che si è disposti a correre di rigettare l'*ipotesi nulla* quando essa è vera (*errore del primo tipo*, ovvero *falso positivo*)
 5. determinare le code della distribuzione normale
 - a. una coda, per differenze in un verso specifico, *per capire se A è migliore di B (o viceversa) si osserva il one-tailed p-value*
 - b. due code, per differenze in un verso o nell'altro, *per capire se A e B sono diversi si osserva il two-tailed p-value*

6. determinare se la distribuzione oggetto di studio è normale
7. selezionare un test statistico appropriato, sulla base delle variabili e della distribuzione eventualmente normale
8. eseguire i test statistici sui dati ed interpretare il risultato
ovvero, *confrontare il p-value* ottenuto rispetto all'*alpha iniziale*
9. rifiutare o non rifiutare l'ipotesi nulla

quattro combinazioni di analisi di H0.

- rigettare un'ipotesi vera, *falso positivo o errore del I tipo, alpha*
- rigettare un'ipotesi falsa, *inferenza corretta, 1-beta*
- non rigettare un'ipotesi vera, *inferenza corretta, 1-alpha*
- non rigettare un'ipotesi falsa, *falso negativo o errore del II tipo, beta*

power del test.

Si chiama *power* del test *1-beta*, ovvero la sua capacità di vedere una differenza, se essa è presente.

Si adotta l'*euristica di Cohen*, che prevede di tenere *alpha* quattro volte più piccolo di *beta*, quindi un *power* del test dell'80%.

p-value.

Il *p-value* è la *probabilità* di raccogliere *dati* come quelli raccolti (o ancora più estremi) assumendo l'*ipotesi nulla H0* come vera.

$$= P(D|H0), \text{ né } P(D) \text{ né } P(H0|D), \text{ (formula di Bayes)}$$

Se questa probabilità è *bassa*, ovvero *inferiore* al 5%, è *improbabile* che la differenza sia unicamente dovuta al caso.

Se il *p-value* è *inferiore* al livello di significatività definito a priori (ad esempio, *alpha* = 5%), allora si può *rigettare H0* e *congetturare* che *H1*, ovvero il suo contrario, sia vero.

Altrimenti, se il *p-value* è *maggiore o uguale* ad *alpha*, il confronto è stato ugualmente utile, ma *non* si sono raccolte *prove sufficienti* che vi siano *reali differenze*.

Se non si riesce a rigettare *H0* *non* significa che sia *sicuramente vera*, continua a *rimanere assunta come vera*.

Se anche si può rigettare *H0*, non è detto che le *differenze* siano *praticamente significative*, oltre che *statisticamente significative*.

i passi del rituale nullo.

Il *rituale nullo* prevede i seguenti passi:

- pensare ad un'ipotesi nulla
- essa prevede un modello su come dovrebbero essere distribuiti i dati
- scegliere uno strumento di misura e la relativa metrica
- raccogliere i dati sperimentali, che hanno una loro distribuzione
- scegliere un test statistico
- il test confronta i dati osservati con quelli ipotizzati
- calcola la probabilità di avere quei dati (o più estremi) se *H0* è vera (= il *p-value*)
- fissare una soglia tale per cui i dati si ritengono troppo strani per essere veri (se i dati sono veri, l'ipotesi è infondata)

- rigettare H_0 e pensare che l'alternativa sia plausibile se il p-value è sufficientemente basso
- riportare i risultati in maniera chiara e semplice, seguendo lo standard APA (American Psychology Association)

Standard APA (American Psychology Association)

- *si dice cosa si è fatto*
 - un t-test per campioni indipendenti è stato eseguito per confrontare [la variabile di interesse, es: il tempo di esecuzione del task 1] usando il [sistema A] e il [sistema B].
 - uno zeta score test è stato eseguito per confrontare il tasso di errori nel compiere il task 1 usando il [sistema A] e il [sistema B].
- *si dice cosa si è ottenuto*
 - in base a tale test, si è trovata una differenza [non] significativa per [la variabile di interesse] tra il [sistema A] ($M = [\text{il valore della media}] \pm [\text{intervallo di confidenza}]$) e il [sistema B] ($M = [\text{il valore della media}] \pm [\text{intervallo di confidenza}]$); $t([\text{gradi di libertà, se noti, altrimenti non mettere nulla}]) = [\text{il valore di } t, \text{ solo se noto}]$, $p = [\text{il valore di } P, \text{ esatto}]$.
 - in base a tale test, si è trovata una differenza [non] significativa riguardo al tasso di errore tra il [sistema A] ($\text{proporzioneA} \pm [\text{intervallo di confidenza}]$) e il [sistema B] ($\text{proporzioneB} \pm [\text{intervallo di confidenza}]$); $z \text{ score} = []$, $p = [\text{il valore di } P \text{ esatto}]$.
 - nel caso in cui non si sia osservata *nessuna differenza*, lo si riporta.
 - p-value riportato in decimale (senza il primo zero) o percentuale.
 - p-value riportato con non più di tre cifre decimali.
- *si spiega cosa si è ottenuto*
 - questo risultato suggerisce che gli utenti impiegano un tempo significativamente minore per eseguire il task 1 usando il [sistema A/B] rispetto a quando usano il sistema [sistema B/A].
 - questo risultato suggerisce che gli utenti [non] commettono più errori per eseguire il task 1 usando il [sistema A/B] rispetto a quando usano il sistema [B/A].
 - oppure, si dice che *impiegano un tempo equivalente utilizzando i due sistemi*

per eseguire i test: [Statistics Kingdom](https://www.statisticskingdom.com/)

Esempi di Variabili Misurabili

- (1) Time to complete task.
- (2) Percentage of task completed.
- (3) Percentage of task completed per unit time (speed metric).
- (4) Ratio of successes to failures.
- (5) Time spent on errors.
- (6) Percentage number of errors.
- (7) Percentage or number of competitors that do this better than current product.
- (8) Number of commands used.
- (9) Frequency of help or documentation use.
- (10) Time spent using help or documentation.
- (11) Percentage of favourable:unfavourable user comments.
- (12) Number of repetitions of failed commands.
- (13) Number of runs of successes and of failures.
- (14) Number of times the interface misleads the user.
- (15) Number of good and bad features recalled by users.
- (16) Number of available commands not invoked.
- (17) Number of regressive behaviours.
- (18) Number of users preferring your system.
- (19) Number of times users need to work around a problem.
- (20) Number of times the user is disrupted from a work task.
- (21) Number of times the user loses control of the system.
- (22) Number of times the user expresses frustration or satisfaction.

(Preece, 1994)

Ingegneria dell'Usabilità

Efficienza d'Uso

Il sistema deve essere efficiente da usare cosicché, quando l'utente lo ha appreso, sia possibile un alto livello di produttività.

Un modo per misurare l'efficienza è calcolare il tempo necessario ad eseguire il compito correttamente. Se si impiega troppo tempo (è possibile dare suggerimenti) o non si riesce a raggiungere l'obiettivo, si assegna un tempo massimo, giustificando le scelte.

soggetti uguali e soggetti diversi.

Se si usano gli *stessi soggetti*, i campioni sono *dipendenti/accoppiati/correlati*.

Se si usano *soggetti diversi*, i campioni sono *indipendenti/disaccoppiati*.

valutazione dell'efficienza - assoluta.

Occorre *confrontare* la *performance* degli utenti con l'*optimal execution time (OET)*.

Per calcolare l'OET occorre eseguire sei prove di esecuzione del task, in maniera corretta e a varie velocità (senza esagerare), riportando i tempi di esecuzione.

Calcolare *media* e *deviazione standard* e confrontare la media cronometrica con quella degli utenti opportunamente formati.

valutazione dell'efficienza - confronto tra due applicazioni.

Applicare un *test ANOVA*, che *generalizza* i *test t di Student*.

In caso di *tre applicazioni*, prima si applica l'ANOVA e successivamente si applica la *t di Student* a *coppie*.

Efficacia (o Robustezza)

Il sistema deve indurre un *basso tasso di errore* (o prevenirli proattivamente), *facili da correggere* e con *basso impatto*.

come misurare l'efficacia.

Un modo per misurare l'efficacia è calcolare il *tasso di errore medio* dei soggetti del campione quando questi usano il *sistema A* e confrontarlo con il *tasso medio* quando gli stessi utenti usano il *sistema B* o *A'*.

Il *tasso di errore* di un soggetto è il *numero di errori* (le volte che non raggiunge l'obiettivo del task) messo in *rapporto* con il *numero di tentativi* (che può anche essere uno solo, *pass* or *fail*).

matrice task-utenti.

Consente di avere un'*idea qualitativa* di quanto è difficile usare un sistema, oltre il semplice numero dell'*error rate*.

Per gestire le *ambiguità*, si registrano i task *eseguiti perfettamente o quasi (verde)*, quelli *eseguiti correttamente ma in maniera non ottimale o con alcuni suggerimenti (giallo)*, e quelli *falliti a causa di veri e propri errori (rosso)*. Ai fini dell'interpretazione, i *gialli* devono essere considerati come *successi (verdi)* o *insuccessi (rossi)*.

se l'utente ha ricevuto una formazione adeguata, allora si può essere severi.

Il confronto si fa tra i sistemi A e B a parità di task, per ciascun task.

valutazione dell'efficacia - assoluta.

Occorre confrontare per ogni task il numero di errori osservato nel campione di utenti con un tasso ottimale (solitamente, 5% o 1%).

Occorre utilizzare il test del Chi Quadro.

valutazione dell'efficacia - confronto tra due applicazioni.

Applicare un two proportion test, che generalizza il test del Chi Quadro.

Apha di Krippendorff per le espressioni facciali (per la Lode).

Soddisfazione

Il sistema deve essere gratificante da usare.

Misura è oggettiva: si effettuano misurazioni psicofisiologiche per misurare i livelli di stress o di benessere.

Misura soggettiva di un osservatore esterno: si conta il numero di espressioni facciali legate a frustrazione, incomprensione e perplessità, e quelle legate a soddisfazione, piacere e sorpresa positiva.

approccio di John Stuart Mill.

La misura è soggettiva da parte dell'utente stesso, attraverso uno strumento psicometrico, ad esempio un questionario con item a scale ordinali ed un uso preparato e responsabile delle tecniche statistiche opportune.

scala Likert.

Consente di registrare le opinioni delle persone sotto forma di grado di accordo con le opinioni del ricercatore.

Una scala ordinale su cui il rispondente mappa il suo grado d'accordo con un'affermazione proposta dallo sperimentatore. Sarebbe meglio adottare una scala a sei valori (pari) per non depotenziare il test, altrimenti (dispari) il middle value viene utilizzato come valore di rifugio:

- | | |
|---------------------------------------|-----------------------------|
| 1. fortemente d'accordo | oppure fortemente d'accordo |
| 2. d'accordo | / |
| 3. parzialmente d'accordo | / |
| 4. parzialmente contrario | / |
| 5. contrario | / |
| 6. fortemente contrario | fortemente contrario |
| 7. (99.) non saprei (opzione di fuga) | |

scala di Likert - vantaggi.

1. molto nota, familiare a potenziali soggetti.
2. semplice da capire, veloce da rispondere.

scala di Likert - svantaggi.

1. misura l'accordo del soggetto con affermazioni dello sperimentatore: ci può essere un forte acquiescence bias (tendenza all'accondiscendenza).
2. se si adotta un numero dispari di opzioni ci può essere anche un forte central tendency bias (tendenza alla risposta centrale o neutra).

tendenza all'accondiscendenza.

Bias dovuto alla tendenza di certi rispondenti a preferire la connotazione positiva delle opzioni fornite, ad essere d'accordo con le domande dei ricercatori e ad aiutarli (è simile al *social desirability bias*).

tendenza alla risposta centrale o neutra.

Bias dovuto alla tendenza di certi rispondenti a preferire l'opzione di mezzo, perché meno impegnativa, più veloce (non ci si deve pensare) e non richiede di prendere una posizione.

NPS - Net Promoter Score

qual è la probabilità di consigliare la fruizione di un servizio o l'acquisto di un bene ad amici o conoscenti o colleghi

scala ordinale.

- **DETRATTORI** tra 0 e 6 - non manifestano soddisfazione per il prodotto e, anzi, potrebbero spargere la voce in modo negativo, sconsigliando il prodotto.
- **PASSIVI** 7 e 8 - persone soddisfatte ma non entusiaste, che potrebbero essere tentate da altri fornitori migliori e che difficilmente potrebbero cantare le lodi del prodotto ad amici e conoscenti.
- **PROMOTORI** 9 e 10 - persone entusiaste, che consigliano caldamente il prodotto agli altri.

formula.

$NPS = (\text{percentuale di promotori}) - (\text{percentuale di detrattori})$

note.

ogni qualvolta viene richiesta un'opinione in una scala tra zero e dieci, dietro di essa si cela un Net Promoter Score.

per visualizzare il NPS, <https://thermostat.io/> e (divergent) stacker bar o butterfly diagram.

contro

- misura solo la raccomandabilità
- (in Italia) può essere confuso con un voto da 0 a 10 (correzione: richiedere una probabilità dallo 0% al 100%)

pro

- la raccomandabilità è molto importante
- considera l'acquiescence bias (*bias di accondiscendenza*)
- considera il central tendency bias (*bias di accondiscendenza*)
- non considera come cardinali delle categorie ordinali (normalizza una differenza di numerosità)
- è semplice e permette confronti nel tempo

Questionari Psicometrici Usati più Frequentemente nella Valutazione della Soddisfazione Percepita

1) SUMI - Software Usability Measurement Inventory

Si tratta di un metodo per misurare la qualità di sistemi interattivi *dal punto di vista dell'utente*, ovvero la *quality of use*, in cinque sottodimensioni:

- *efficiency*
- *affect*

- *helpfulness*
- *controllability*
- *learnability*

com'è fatto.

Si compone di *50 domande (item) con tre valori di risposta*, perciò non fa *nulla* per *mitigare* il *central tendency bias*. Una soluzione sarebbe separare l'opzione *undecided* dalle opzioni *agree* e *disagree*.

Inoltre, si compone di *tre domande aperte*:

- in generale, per cosa si utilizza il software
- qual è l'elemento del software che piace di più e perché
- qual è l'elemento del software che ha bisogno di più miglioramento e perché

Infine, prevede due domande di profilazione per stratificare le successive analisi statistiche:

- analisi di importanza
- grado di familiarità

Gli ultimi due *item* possono essere considerati *variabili indipendenti*, mentre gli altri sono *variabili dipendenti*.

vantaggi.

- facile da usare
- risultati facili da comunicare
- utilizzabile in contesti differenti
- permette domande aperte e feedback dell'utente
- viene suggerito dall'ISO 9241 per testare la *user satisfaction*

svantaggi.

- non è facile trovare la *traduzione italiana validata*
 - i questionari psicometrici prevedono domande poste in maniera tale affinché si possano aggregare in costrutti di alto livello, perciò è importante una traduzione validata (che coinvolge un certo numero di persone e madrelingua)
- necessaria una licenza per utilizzarlo in contesti istituzionali o aziendali
- lungo, ai limiti della soglia del *fatigue bias*
- richiede un uso prolungato da parte dell'utente

2) AttrakDiff

Si tratta di un questionario per valutare la valutazione della *User Experience*, in *quattro ambiti*:

- *Pragmatic Quality - PQ* - riguarda l'usabilità in termini di utilità ed efficacia
- *Hedonic Quality - HQ* - riguarda l'esperienza estetica relativa al bello
 - *Identity - HQ-I* - identificazione dell'utente con il prodotto o la marca in un dato contesto sociale
 - *Simulation - HQ-S* - soddisfazione di bisogni in termini di voglia di nuovo, desiderio di padroneggiare uno strumento e di interazione stimolante
- *Evaluation Constructs* - riguarda il bello ed il buono

differenziale semantico.

Utilizza una *scala differenziale*, che sembra continua, ad *ancore implicite* ad eccezione degli *estremi*, avente *significato semantico opposto*.

vantaggi.

- misura dimensioni della User Experience, difficili da catturare
- usa scala a differenziale semantico
- ha una rappresentazione grafica appetibile (chiamato *snake diagram*)

svantaggi.

- non ha una *traduzione italiana validata*
- non minimizza il *central tendency bias* (dove porre inizialmente lo slider?)
- si basa su concetti semantici di non ovvia interpretazione
- come indicatore quantitativo adotta la *media*, per *singola posizione*, delle medie, dei singoli rispondenti, trasformando posizioni su scala in numeri

3) UEQ - User Experience Questionnaire

Si tratta di un questionario di 26 item a *differenziale semantico*, in *sei sottoscale*:

- *attractiveness* - attraente, piacevole
- *perspicuity* - facile da capire e imparare
- *efficiency* - efficiente, veloce
- *dependability* - ci si può affidare, predicibile
- *stimulation* - eccitante, interessante
- *novelty* - creatività, innovatività

correlazione.

Come nel caso dell'NPS, gli *score correlano* con altre *misure*.

ad esempio, correlazione con i tempi di completamento di un task.

- | | |
|-------------------------|--------|
| • <i>attractiveness</i> | - .54 |
| • <i>perspicuity</i> | - .66* |
| • <i>efficiency</i> | - .73* |
| • <i>dependability</i> | - .65* |
| • <i>stimulation</i> | .10 |
| • <i>novelty</i> | .29 |

* = significativo a livello di confidenza del 95%

se $0.05 < p < 0.01$

** = significativo a livello di confidenza del 99%

se $0.01 < p < 0.001$

*** = significativo a livello di confidenza superiore al 99% (99.9%) se $p < 0.001$

note.

tradurre la versione in inglese in italiano, correttamente.

vantaggi.

- ha traduzioni validate in molte lingue
- breve e utilizza parole più semplici dell'AttrakDiff
- copre aree semantiche importanti
- ottima *documentazione* (ad esempio, <http://www.ueq-online.org/>)
- fornisce un *tool di analisi dei dati* (ad esempio, Microsoft Excel)
- fornisce un *data set* per fare *benchmark*

svantaggi.

- non minimizza il central tendency bias

- come indicatore quantitativo adotta la media (per singola dimensione) delle medie (dei singoli rispondenti) trasformando posizioni sulla scala

4) SUS - System Usability Scale

Si tratta di un *decalogo* (10) su *cinque livelli* di risposta, e *Likert* ma, anziché essere un'affermazione del ricercatore (e l'utente stabilisce quanto è d'accordo), fa un'affermazione in prima persona e chiede all'utente quanto la farebbe propria.

come fare.

1. per gli item dispari, il contributo allo score è dato dal valore scelto dall'utente meno 1.
per gli item pari, il contributo allo score è dato dalla differenza tra 5 e il valore scelto dall'utente.
questo consente di convertire tutte le risposte tra 0 e 4.
2. somma tutte le risposte di un singolo utente e moltiplica il risultato per 2.5 per ottenere il valore totale per un utente
3. poi, fa la media tra tutti gli score individuali
4. infine, interpreta: uno score SUS medio sopra il 68 sarebbe da considerarsi sopra la media (risultato buono)

attenzione all'errore.

i valori degli utenti devono essere trasformati (dispari decrementati e pari girati) subito, prima di riportare i dati in formato tabellare, visualizzarli come boxplot e fare il calcolo dello score.

vantaggi.

- breve e veloce da compilare
- restituisce un risultato tra 0 e 100
- noto e utilizzato
- minimizza l'*option order bias* e l'*acquiescence bias* (è a scale invertite)

svantaggi.

- somma di valori ordinali, normalizza la somma per ciascun rispondente in centesimi e poi fa la media tra tutti i rispondenti
- mescola usabilità e apprendibilità
- non si possono fare confronti statisticamente significativi (a meno di non isolare i singoli item)

SUS score

Lo *SUS score* è un numero un po' discutibile, però il questionario può essere utile per confrontare i sistemi anche considerando singolarmente gli item (1 soddisfazione, 3 facilità d'uso, 7 learnability, 8 efficienza). Per i singoli item si possono fare test binomiali e di Mann-Whitney.

Euristiche del Form

buone scelte.

- riportare le percentuali di risposta, non la media, e fare i boxplot
- non mettere l'opzione centrale (meglio 6 o 4 di 5 o 7)
- essere espliciti nell'opzione di rifugio, ma non preselezionarla
non saprei, non so cosa rispondere, ...
- evitare gli slider (danno una sensazione di continuità), meglio i radio button
- adottare un ordine randomico per gli item
- meglio non mettere tutti i numeri, solo gli estremi
- attenzione all'*effetto prime*, ovvero al verso della scala

effetto prime.

Si tratta di un *order bias* legato alle *opzioni di risposta*, in quanto le scale ordinali non possono essere riordinate randomicamente: i primi e gli ultimi valori della scala sono scelti più frequentemente, poiché letti per primi o per ultimi.

L'*opzione preferita* conviene collocarla all'inizio di una scala corta o alla fine di una scala lunga.

estrarre una valutazione euristica.

Per estrarre una *valutazione euristica* da *scale ordinali*: contare il numero di risposte nella metà positiva e nella metà negativa (decidendo come partizionare se pari), poi o fare la differenza tra le proporzioni (come NPS) o con gli IC.

Box Plot e Violin Plot

La distribuzione di risposte su cale ordinale può essere caratterizzata da moda, mediana e somma di ranghi (*non la media*). La visualizzazione migliore è, *per ogni item*, quella del box plot *con i baffi*.

Per le distribuzioni dei tempi di risposta, adottare i *violin plot*.

(<http://shiny.chemgrid.org/boxplotr/>)

box plot - per le scale ordinali.

violin plot - per le scale continue (come i tempi di risposta).

(<https://statskingdom.com>)

correzione di Bonferroni.

Se il livello di confidenza è del 95% e vi sono almeno 20 confronti, allora ci si può aspettare di trovare almeno un risultato significativo che non c'è veramente (falso positivo).

Allora, si applica la correzione di Bonferroni e si considera un livello di significatività di α/k dove k è il numero di *sistemi*.

descrivere applicazione e risultato Mann-Whitney e test (dei ranghi con segno) di Wilconxon.

Un test Mann-Whitney U test è stato eseguito su N partecipanti per determinare se ci fossero differenze significative per quanto riguarda [la dimensione X] percepita usando il [sistema A] e il [sistema B] (oppure tra [gruppo 1] (N1 = numero partecipanti gruppo 1) e [gruppo 2] (N2 = numero partecipanti gruppo 2) usando un solo sistema).

In base a tale test, si è trovata una differenza [non] statisticamente significativa tra le percezioni mediane relativamente alla [dimensione X] per il [sistema A] (o il gruppo 1) (MedianA) e il sistema B (o il gruppo 2) (MedianB), $U = [\text{valore di } U]$ $p = [\text{valore di } p]$.

Questo risultato suggerisce che gli utenti percepiscono una [la dimensione X] significativamente minore usando il [sistema A/B] rispetto a quando usano il sistema [sistema B/A] (oppure: suggerisce che [i membri del gruppo 1] percepiscono una [la dimensione X] significativamente più bassa dei [membri del gruppo 2] usando il [sistema A]).

Ricapitolando - Per il Progetto d'Esame

- 1) selezionare un questionario che misuri la soddisfazione, motivando la scelta (semplicità, completezza, diffusione, benchmarking).
- 2) implementarlo su una piattaforma online (Google Forms, Limesurvey, SurveyMonkey) aggiungendo 3 domande di profilazione (genere, classe di età e familiarità con tecnologie Web).
- 3) farlo compilare ai rispondenti (almeno 24).
- 4) riportare tutte le risposte in formato tabellare.
- 5) visualizzare sotto forma di diagramma Box Plot o Violin Plot.
- 6) riportare gli score, se previsti, per ciascun sistema ed eventualmente sottogruppi di rispondenti (donne o uomini, junior o senior).
- 7) selezionare 2 o 3 item rilevanti dal questionario e, per ciascuno di questi, eseguire test Mann-Whitney (o Kruskal Wallis) per identificare eventuali differenze statisticamente significative.
- 8) riportare il risultato del test in maniera chiara e semplice.

learnability - si misura il tempo con cui gli utenti riescono ad arrivare ad un livello di produttività dopo una fase *uniforme* di formazione (*video o presentazione - da mettere come appendice alla relazione di progetto*), oppure si registra il numero di compiti portati a termine con successo in un determinato periodo di tempo.

memorability - si misura facendo imparare ad usare il sistema ad un campione di persone e poi coinvolgendoli di nuovo a distanza di tempo (*almeno un giorno, periodo di washout*) e misurando il numero di errori in un tempo prefissato, ma senza alcun supporto.

Ricapitolando - Metodi Quantitativi

- identificare uno o più task e confrontare i sistemi a parità di task, non su task diversi
- raccogliere un campione di persone, impostare un livello di confidenza (95%), livello di significatività (5%) e calcolare il test opportuno per ottenere il p-value.
- variabili continue (es. tempi)
 - confronto tra due gruppi (o due sistemi sullo stesso task, o due sottogruppi di utenti per lo stesso sistema e stesso task): *test del T di Student*.
- variabili ordinali (es. scale psicometriche)
 - confronto tra due gruppi (o due sistemi sullo stesso task, o due sottogruppi di utenti per lo stesso sistema e stesso task): *test di Mann-Whitney/Wilcoxon*
 - confronto tra più di due gruppi (o due sistemi sullo stesso task, o due sottogruppi di utenti per lo stesso sistema e stesso task): *test di Kruskal-Wallis/Friedman*.
- variabili discrete (e dicotomiche, es. numero di errori)
 - confronto tra due gruppi (o due sistemi sullo stesso task, o due sottogruppi di utenti per lo stesso sistema e stesso task): *tavola di contingenza 2x2 del Chi Quadro*.
- valutazione assoluta su scala psicometrica
 - per ciascun item, confrontare numero di risposte positive e numero di risposte negative e applicare un test binomiale oppure confrontare le

proporzioni con gli intervalli di confidenza; per 2-3 item rilevanti Mann-Whitney. Riportare i risultati e commentarli.

Ricapitolando - La Relazione di Progetto Deve Comprendere

- la distribuzione delle responsabilità.
- perché è stato scelto quel dominio applicativo.
- la descrizione sommaria del sistema/i confrontata/i e con alcuni screenshot.
(mercato, popolarità, numero di download)
- la parte di valutazione euristica (soprattutto i casi notevoli).
- la descrizione dei task.
- la scelta del questionario (e perché).
- la tabella dei risultati (tempi, errori, questionari psicometrici); nel caso degli errori anche la matrice cromatica.
- molto importante: la visualizzazione dei risultati. l'occhio vuole la sua parte. barchart per error rate, boxplot per percezioni psicometriche e violin plot per tempi.
- tutti i test statistici fatti e i loro risultati, secondo le buone convenzioni di reporting (es. APA), quindi anche con una conclusione che sia comprensibile ad un profano (gorilla).
- analisi espressioni facciali e/o eye tracking valore aggiunto.

3 + 3 *euristica*
12 *user test*
24 *questionari*